Αναγνώριση Προτύπων και Μηχανική Μάθηση

Παπαδόπουλος Ιωάννης-Ραφαήλ / ΑΕΜ:10696 / Ομάδα 30

Μέρος Α

Στο πρώτο μέρος της εργασίας χρησιμοποιούμε το dataset1 που περιέχει 100 δείγματα για κάθε μια από τρεις κλάσεις. Θεωρώντας πως τα δείγματα κάθε κλάσης προέρχονται από μια διαφορετική κανονική κατανομή πρέπει με την μέθοδο της μέγιστης πιθανοφάνειας (maximum likelihood) να βρούμε τις παραμέτρους των κατανομών και να σχεδιάσουμε τις κατανομές σε ένα ενιαίο plot.

Περιγραφή των δεδομένων

Αρχικά φορτώνουμε τα δεδομένα και τα μετατρέπουμε σε ενα pandas dataframe για ευκολότερο χειρισμό. Χρησιμοποιούμε την συνάρτηση describe και βγάζουμε κάποια αρχικά συμπεράσματα για τα δεδομένα μας.

```
...                 X1          X2       Class
    count  300.000000  300.000000  300.000000
    mean    32.319677   28.641387    1.000000
    std      7.425101   10.061984    0.817861
    min     13.149767    1.122443    0.000000
    25%     26.728744   20.997999    0.000000
    50%     31.392079   31.482850    1.000000
    75%     38.928159   36.322726    2.000000
    max     47.569759   46.062217    2.000000

    Statistics for each class:

    Class 0 :
      X1: mean = 29.2090, std = 6.8892
      X2: mean = 16.8499, std = 7.0087

    Class 1 :
      X1: mean = 40.1977, std = 3.0853
      X2: mean = 34.2811, std = 4.5068

    Class 2 :
      X1: mean = 27.5523, std = 3.7563
      X2: mean = 34.7932, std = 5.0541
```

Με βάση τα στατιστικά αυτά μπορούμε να συμπεράνουμε πως η τιμή του χαρακτηριστικού X1 μπορεί να διαχωρίσει την κλάση 1 από τις υπόλοιπες και η τιμή του X2 μπορεί να διαχωρίσει την κλάση 0 από τις υπόλοιπες . Συνεπώς η γνώση και των δύο είναι αρκετή για να διαχωρίσει όλες τις κλάσεις μεταξύ τους. Άρα πράγματι οι κανονικές κατανομές έχουν διαφορετικές παραμέτρους.

Οπτικοποίηση

Δημιουργούμε το scatter plot των δεδομένων και το ιστόγραμμα για κάθε χαρακτηριστικό.

Τα συμπεράσματα ταυτίζονται με αυτά που βγάλαμε νωρίτερα.

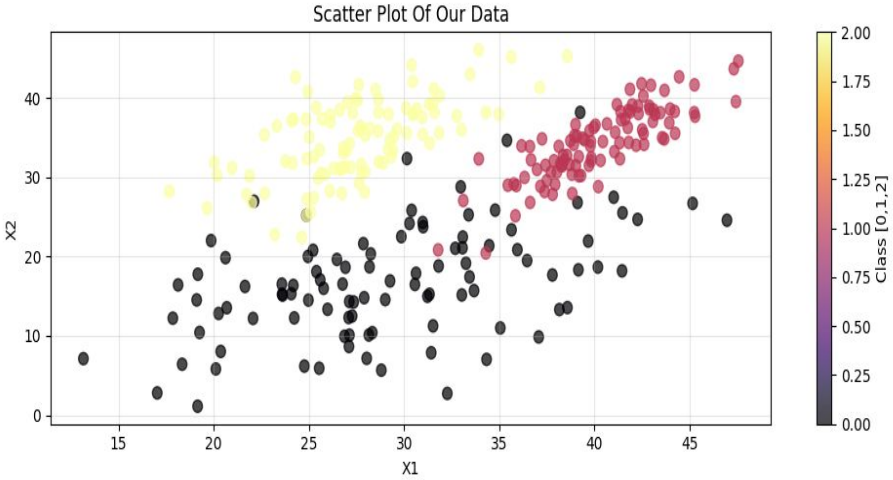

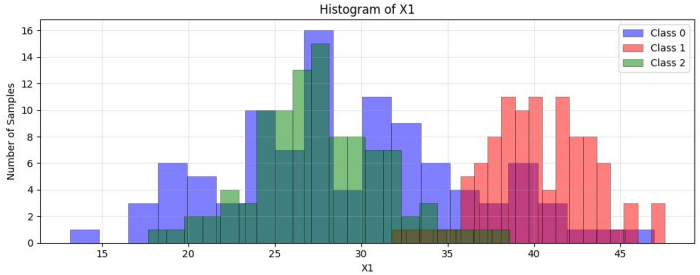

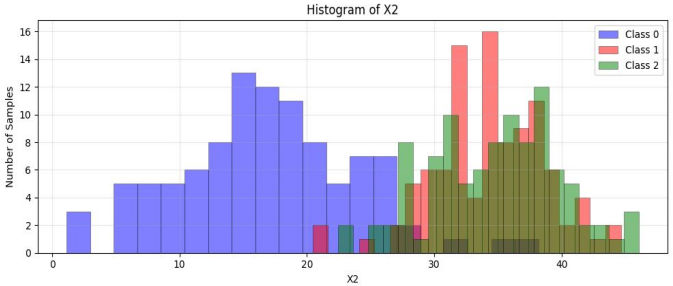

Box-plots

Επίσης δημιουργούμε τα box-plots των χαρακτηριστικών άνα κλάση και αφού έχουμε πάρει μια πρώτη εικόνα για τα δεδομένα μας μπορούμε να προχωρήσουμε στο ζητούμενο.

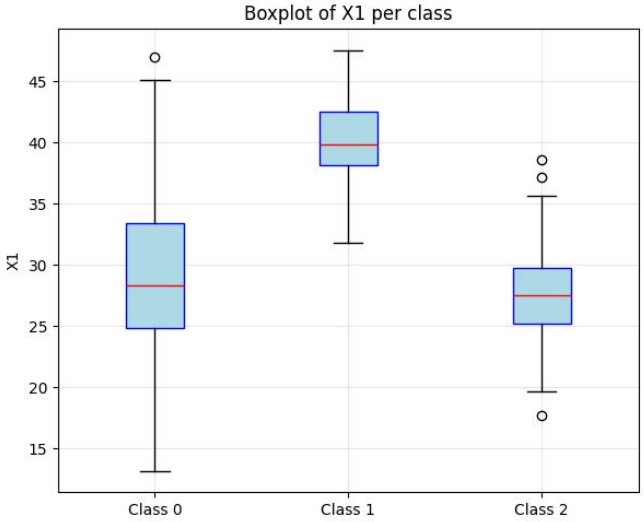

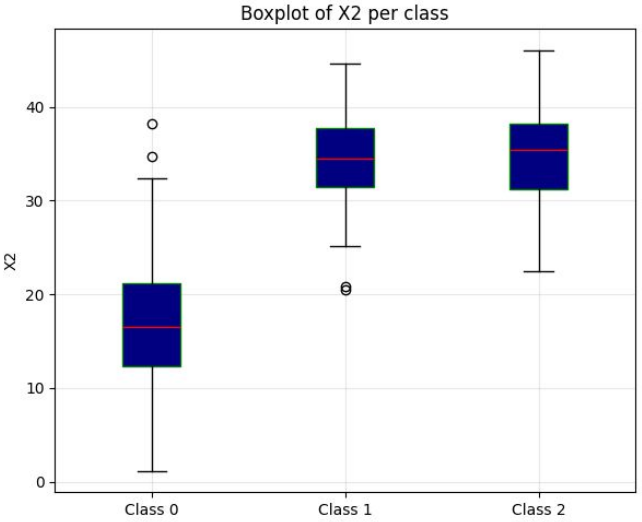

Mean Value and Covariance Matrix

Αφού γνωρίζουμε πως οι κατανομές μας είναι κανονικές χρειαζόμαστε την μέση τιμή και τον πίνακα συνδιακύμανσης για κάθε κλάση.

```
Class 0:
  mean: [29.209038, 16.849889]
  Covariance Matrix Σ:
    [46.985913  22.905323]
    [22.905323  48.631336]

Class 1:
  mean: [40.197669, 34.281091]
  Covariance Matrix Σ:
    [9.423905  11.489718]
    [11.489718  20.108056]

Class 2:
  mean: [27.552325, 34.793180]
  Covariance Matrix Σ:
    [13.968744  11.774336]
    [11.774336  25.288482]
```

Από τα δεδομένα αυτά μπορούμε να δούμε πως τα κέντρα των Gaussian PDFs διαφέρουν και πως τα διαγώνια στοιχεία της κλάσης 0 είναι μεγαλύτερα από ότι των υπολοίπων κλάσεων συνεπώς αναμένεται και περισσότερο πλατιά.

Η εκτίμηση μέγιστης πιθανοφάνειας για κάθε κατανομή δίνεται από τον παρακάτω τύπο.

$$f(x) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right)$$

3D Plot και Ισοϋψείς

Το 3D plot των τριών κατανομών και οι αντίστοιχες ισοϋψείς φαίνονται παρακάτω.

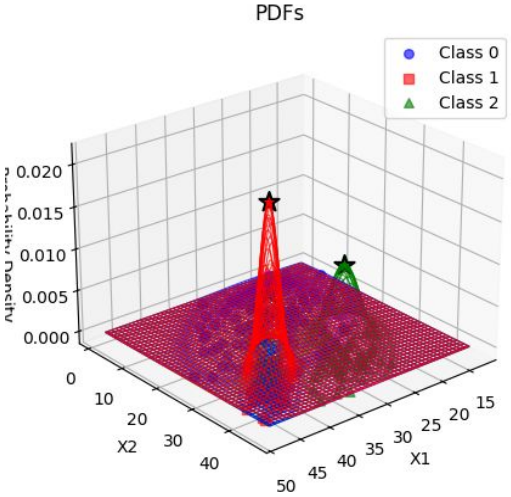

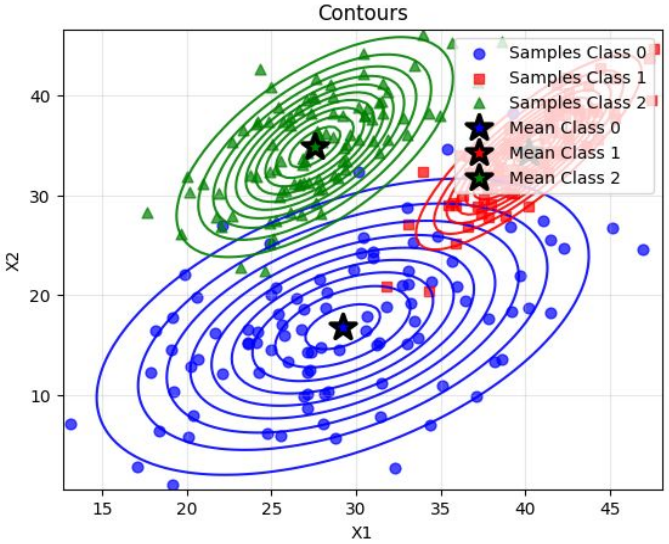

Μέρος Β

Στο δεύτερο ερώτημα χρησιμοποιούμε το dataset2 το οποίο περιέχει 200 μονοδιάστατα δείγματα. Σκοπός είναι με χρήση της μεθόδου Parzen Windows να εκτιμήσουμε την συνάρτηση πιθανότητας της κατανομής των δεδομένων χρησιμοποιώντας ως kernels τα hypercube και gaussian.

Επίσης δίνεται πως θεωρητικά το σύνολο των δεδομένων προέρχεται από κανονική κατανομή N(1,4) και βασιζόμενοι σε αυτό καλούμαστε να ελέγξουμε κατά πόσο ταιριάζει με τα δεδομένα μας και να βρούμε για διάφορες τιμές της παραμέτρου των Parzen Windows (h) την προβλεπόμενη πιθανοφάνεια, την πραγματική και το MSE μεταξύ των δύο.

Περιγραφή των δεδομένων

Μετατρέπουμε τα δεδομένα σε pandas dataframe και καλούμε την συνάρτηση describe για μια πρώτη ματιά στα δεδομένα μας .

```
Shape: (200, 1)

Describe its statistics:
            values
count  200.000000
mean     0.070186
std      1.972615
min     -5.397045
25%     -1.358560
50%      0.168852
75%      1.472168
max      5.395079

 Check whether we have any missing values:
   NaN values: 0
   Null values: 0
```

Η μέση τιμή φαίνεται να είναι κοντά στο 0 (0.07) ενώ μας δόθηκε θεωρητικά η τιμή 1. Η std=1.97 ωστόσο είναι πολύ κοντά στην θεωρητική της τιμή, δηλαδή 2.

Histogram and Box-plot

Για περαιτέρω έλεγχο δημιουργούμε το ιστόγραμμα και το box-plot των δεδομένων.

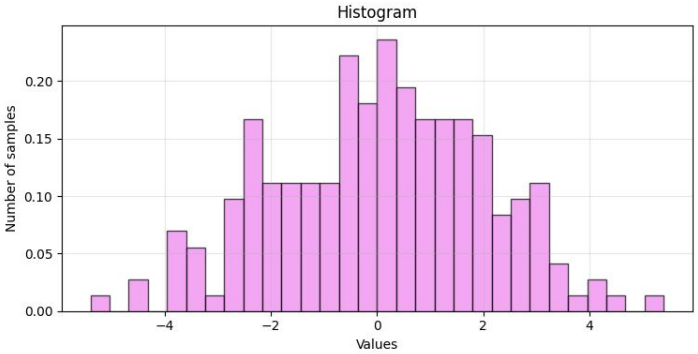

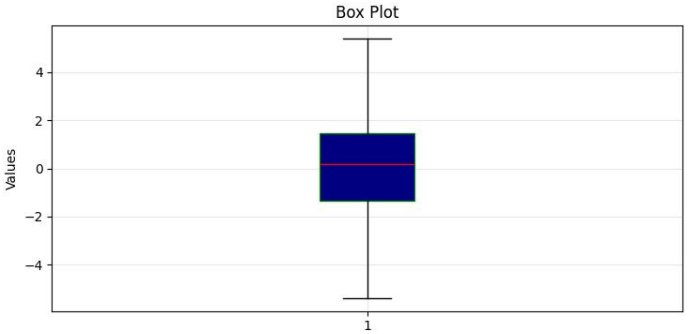

Comparison

Με βάση τις γνώσεις τις στατιστικής τα δεδομένα φαίνεται να ακολουθούν πράγματι κανονική κατανομή με std=2 όμως το κέντρο της μοιάζει να είναι το 0 και όχι το 1 που δίνεται θεωρητικά, αφού για κέντρο το 0 τα median, Q1 και Q3 που υπολογίσαμε μέσω της describe δεν ταιριάζουν με τις θεωρητικές τους τιμές.

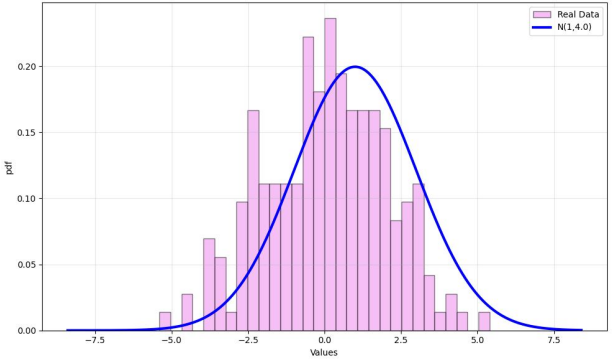

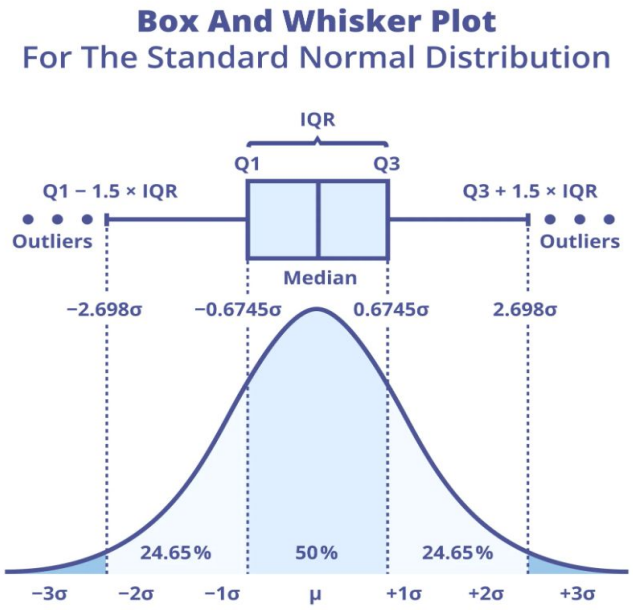

Best h parameter value

Για την αναζήτηση της καλύτερης τιμής της παραμέτρου h θα θεωρήσουμε πως πράγματι τα δεδομένα προέρχονται από την κατανομή N(1,4) και θα αναζητήσουμε την τιμή του h στο διάστημα [0.1,10] με βήμα 0.1 που βελτιστοποιεί το MSE.

Υλοποιούμε την μέθοδο Parzen Windows και την δοκιμάζουμε για διάφορες τιμές του h για δύο πυρήνες (kernels) έναν ασυνεχή (hypercube) και έναν συνεχή (gaussian).

$$\hat{f}(x) = \frac{1}{n \cdot h^d} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

Optimal h

Ο hypercube πυρήνας ελαχιστοποιεί το MSE για h=6.8 ενώ ο gaussian για h=2.0 .

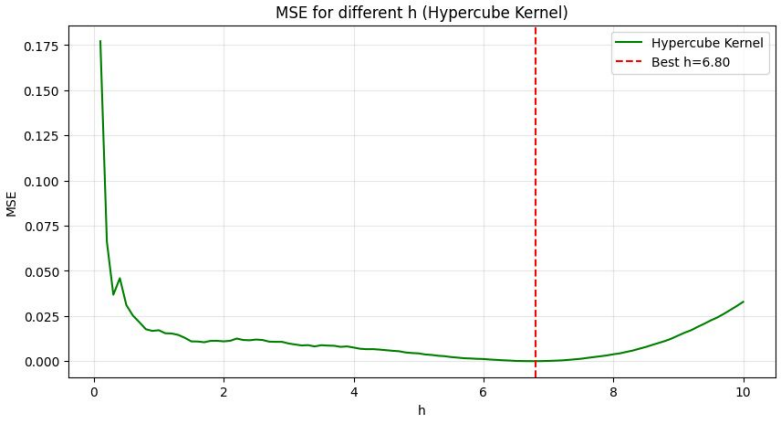

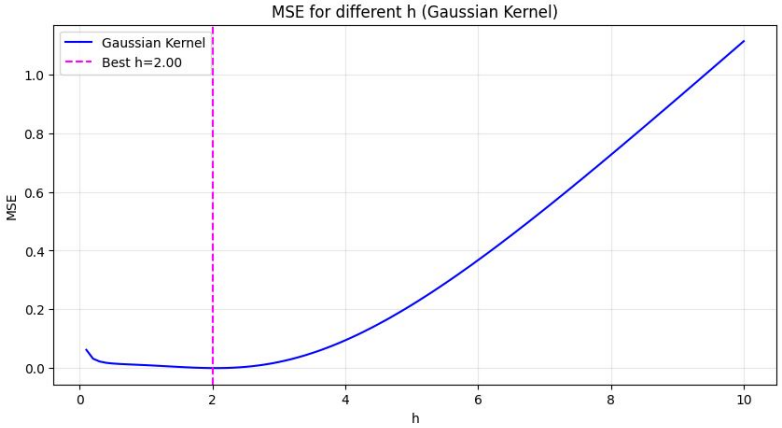

Compromise

Έχω πάντα bias λόγω της διαφωνίας στην μέση τιμή μεταξύ θεωρητικής κατανομής και αυτής που παίρνω από τα δεδομένα.
Δεδομένου ότι το σφάλμα υπολογίζεται ως προς τη θεωρητική κατανομή, η επιλογή του h δεν στοχεύει στην καλύτερη εκτίμηση της πραγματικής πυκνότητας αλλά στην εύρεση του βαθμού εξομάλυνσης που καθιστά τον εκτιμητή όσο το δυνατόν πιο κοντά στο θεωρητικό μοντέλο.

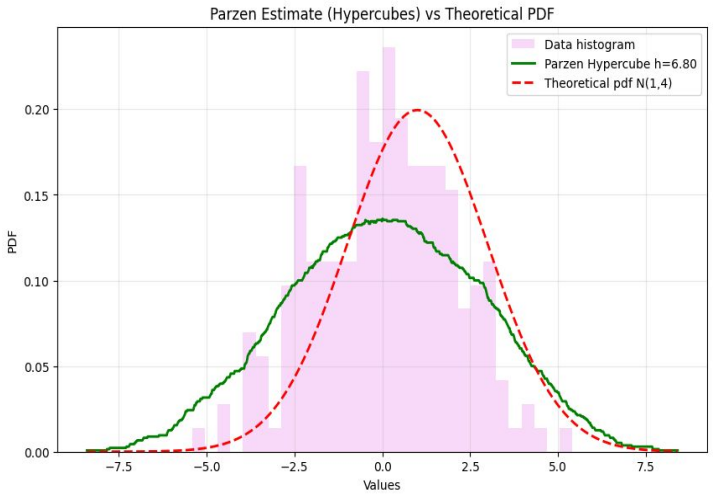

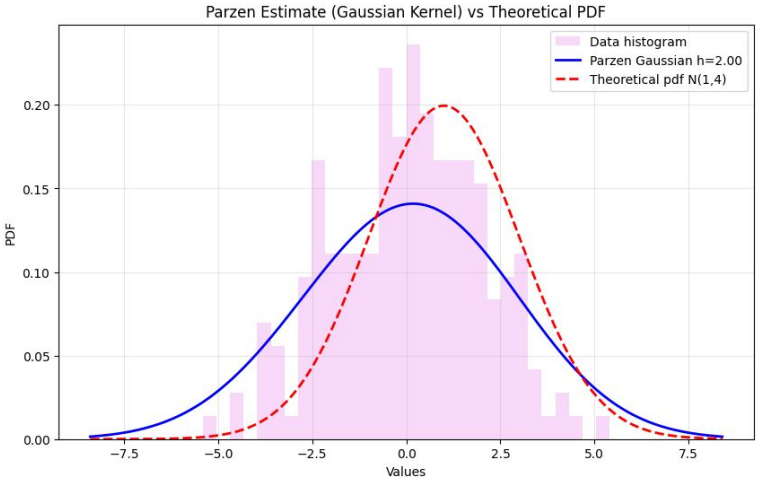

Μέρος Γ

Στο τρίτο ερώτημα χρησιμοποιούμε το dataset3 και το testset. Τα αρχεία περιέχουν από 50 δισδιάστατα δείγματα μαζί με τα labels τους. Καλούμαστε να δημιουργήσουμε έναν k-NN classifier ο οποίος θα εκπαιδεύεται στο dataset3 για το binary classification των δειγμάτων και θα ελέγχεται στο testset.

Η διαδικασία θα επαναληφθεί για διάφορες τιμές της υπερπαραμέτρου k και για αυτήν για την οποία θα έχουμε την μεγαλύτερη ακρίβεια στο testset θα σχεδιάσουμε και τις περιοχές απόφασης.

Optimal k value

Η καλύτερη ακρίβεια είναι 74% για αριθμό γειτόνων k=11.

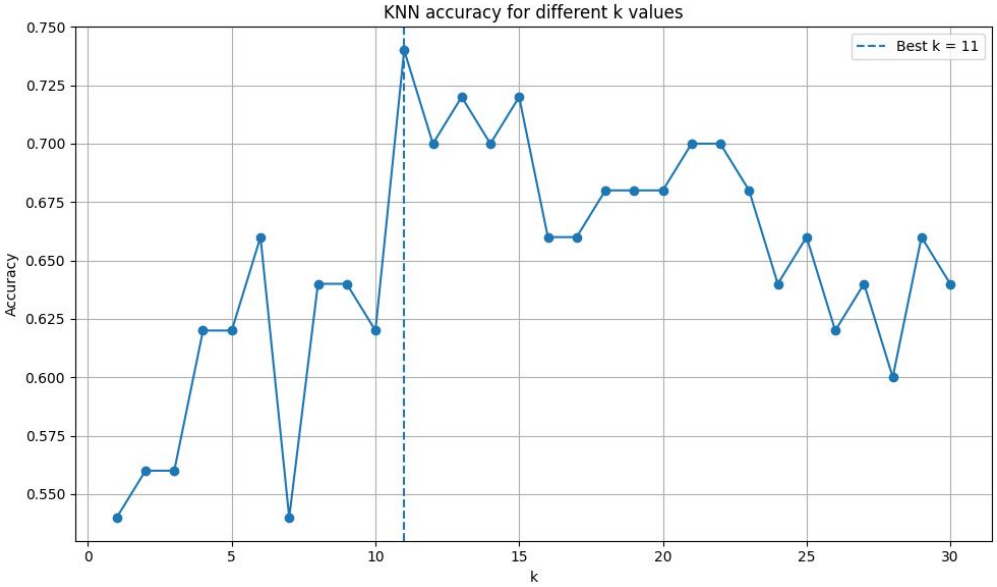

Decision Boundaries

Οι περιοχές απόφασης για το βέλτιστο k=11 φαίνονται παρακάτω.

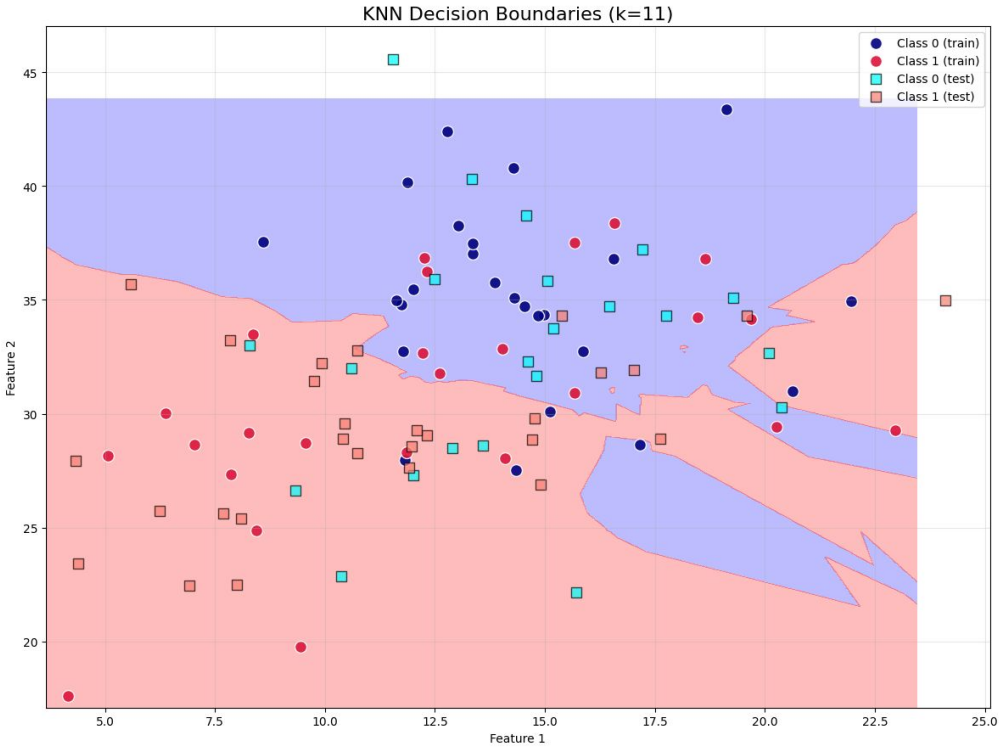

Optimal k

Οι τιμές που ζητήθηκε να δοκιμαστούν για τον k-NN classifier στο διάστημα [1,30].

Η βέλτιστη τιμή βρέθηκε περίπου στην μέση.

Αυτό οφείλεται στο γεγονός ότι όταν το k είναι μικρό ο classifier κοιτάει μόνο τους λίγους κοντινούς γείτονες οπότε είναι εύκολο να έχουμε υπερπροσαρμογή (overfit) και πολύ jagged περιοχές απόφασης. Αντίθετα όταν το k πάρει μεγάλες τιμές ο classifier μπορεί να υποπροσαρμοστεί (underfit) επειδή λαμβάνει υπόψιν σχεδόν όλα τα σημεία και χάνει μικρά μοτίβα και τοπικές λεπτομέρειες και δημιουργεί λείες περιοχές απόφασης.

Low Accuracy

Η μέγιστη ακρίβεια ήταν στο 74% και για τον λόγο αυτό θα κάνουμε οπτικοποίηση των δεδομένων σε scatter plot ώστε να κατανοήσουμε που οφείλεται το άνω αυτό όριο της ακρίβειας.

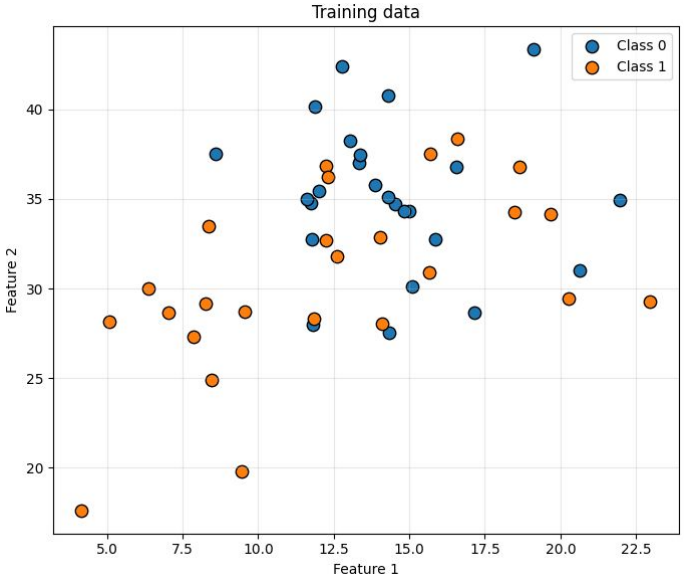

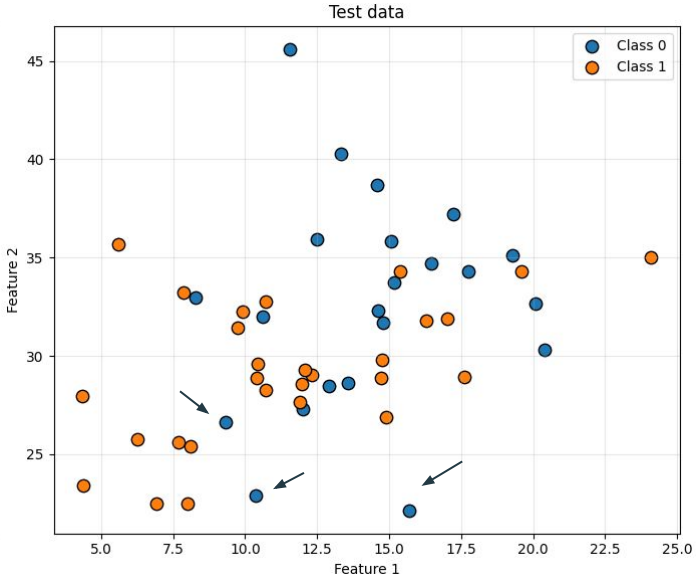

Possible explanations

Μια πιθανή αιτία της χαμηλής ακρίβειας είναι ότι το training set είναι ίδιου μεγέθους με το test set. Έτσι δεν αρκεί το training set ώστε να μάθουμε τα patterns και να πάρουμε μια ορθή εκτίμηση της κατανομής των δύο κλάσεων. Επίσης στο test set μπορούμε να δούμε κάποια δείγματα τα οποία είτε δεν έχουμε ξαναδεί (out of distribution) είτε κάποια δείγματα τα οποία θα ταξινομούσαμε στην λάθος κλάση επειδή δεν έχουμε δει παρόμοια στο training set. Συνεπώς μπορούμε να καταλήξουμε πως το training set δεν ήταν αρκούντως μεγάλο ώστε να αποκτήσουμε μια καλή ιδέα της πραγματικής κατανομής των δύο κλάσεων και έτσι και η ακρίβεια έχει ως άνω όριο το 74%.

Box-plots and Histograms

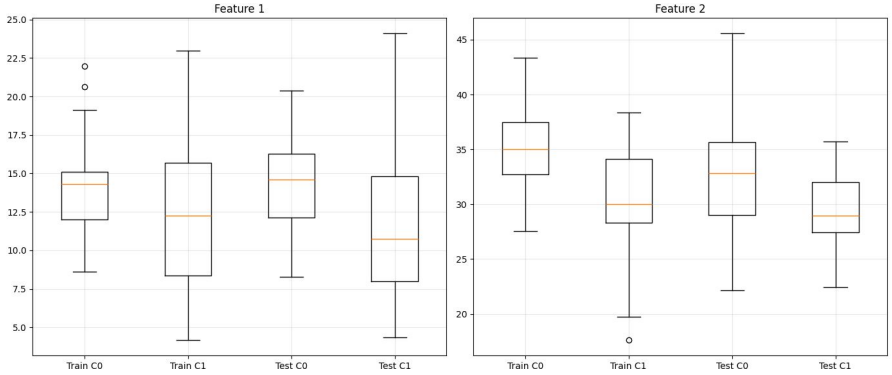

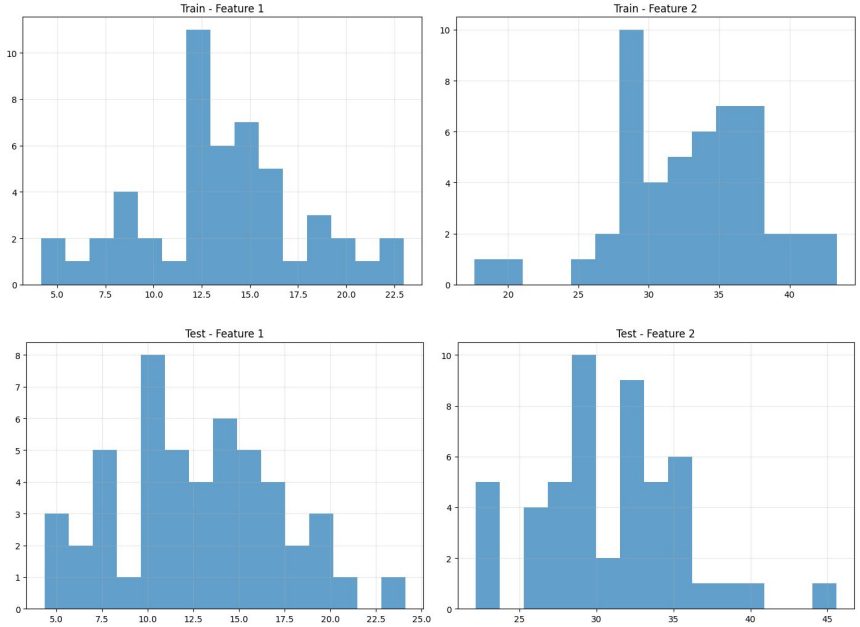

Από τα box-plots και τα ιστογράμματα μπορούμε να καταλήξουμε στα ίδια συμπεράσματα.

Μέρος Δ

Στο τελευταίο ερώτημα εργαζόμαστε με το datasetTV το οποίο περιέχει 8743 δείγματα 224 διαστάσεων με ένα label {1,...,5}. Με το dataset αυτό ως training set μπορούμε να αναπτύξουμε ελεύθερα έναν αλγόριθμο ταξινόμησης και να μετασχηματίσουμε όπως επιθυμούμε τα δεδομένα εισόδου. Ύστερα πρέπει να εφαρμόσουμε το εκπαιδευμένο μοντέλο στο datasetTest που αποτελεί το test set και να εξάγουμε το διάνυσμα labelsX.

Preprocessing-Data Cleaning

Αρχικά μετατρέπουμε τα δεδομένα σε pandas dataframe.

Ελέγχουμε αν οι διαστάσεις ταιριάζουν με αυτές της εκφώνησης και εάν έχουμε missing values.

```
X shape: (8743, 224)
y shape: (8743,)
```

```
NaN values per column (non-zero only):
   0
```

Balanced Classes

Ύστερα βλέπουμε αν οι κλάσεις είναι ισορροπημένες.

224	count
1	1769
2	1720
3	1754
4	1716
5	1784

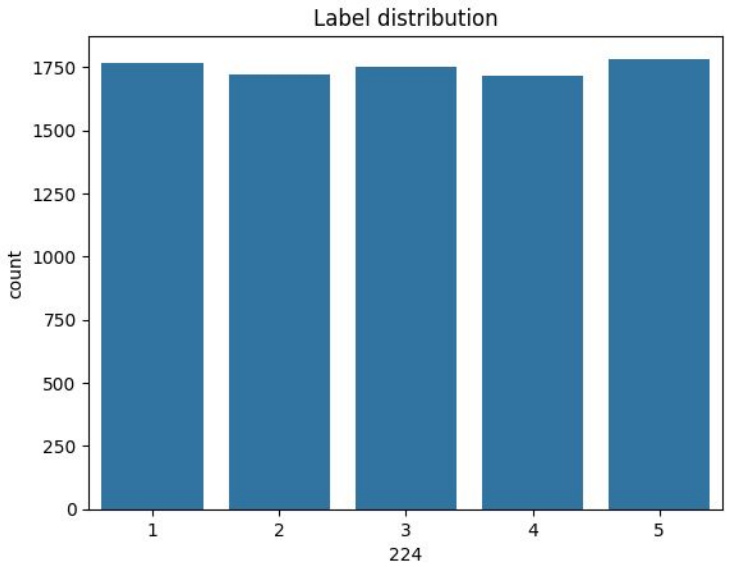

Multidimensional Problem

Επειδή τα δείγματα μας έχουν πολλά features/ πολύ μεγάλη διάσταση δεν είναι εφικτή κάποια άμεση οπτικοποίηση οπότε πρέπει να καταφύγουμε σε εναλλακτικές τεχνικές.

Ελέγχουμε τυπικά εάν υπάρχει κάποια συσχέτιση ανάμεσα στα features για παράδειγμα για να πάρουμε μια πρώτη εικόνα.

Από ότι φαίνεται έχουμε δεν έχουμε κάποια ισχυρή συσχέτιση σε κάποιο μη-διαγώνιο στοιχείο.

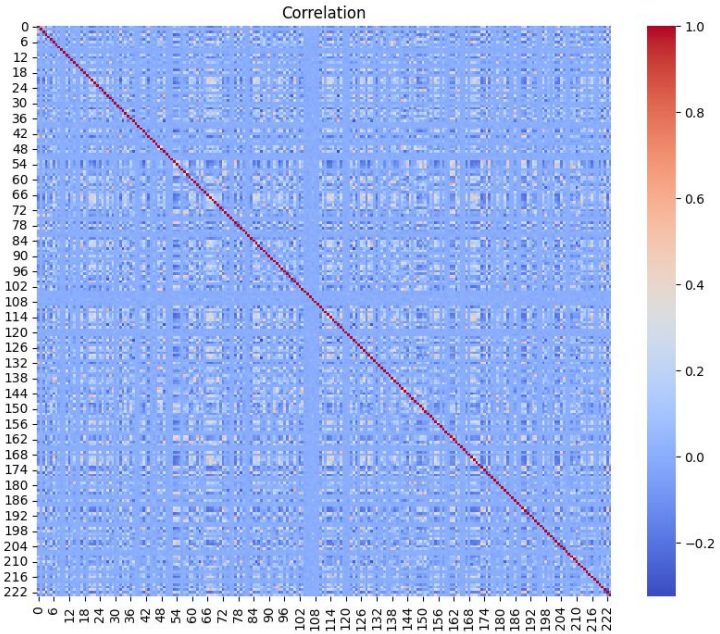

Feature Importance

Εφαρμόζουμε έναν Random Forest Classifier πάνω στο dataset για να δούμε αν έχουμε κάποιο feature με ισχυρή σημαντικότητα.

Δεδομένου ότι έχουμε 224 features και κανένα δεν ξεπερνά την τιμή του 0.01 φαίνεται πως δεν έχουμε κάποιο πολύ ισχυρότερο feature από τα υπόλοιπα.

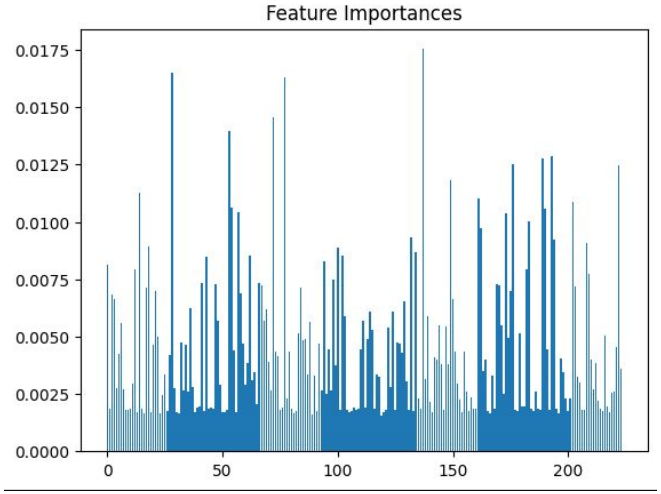

PCA

Εφαρμόζουμε Principal Components Analysis με τιμές διατήρησης διακύμανσης 0.95 και 0.99 και βλέπουμε πόσα principal components χρειάζονται σε κάθε περίπτωση. Από τα αποτελέσματα βλέπουμε πως η PCA μειώνει την διάσταση των δεδομένων ωστόσο όχι σε μεγάλο βαθμό καθώς από τις 224 μέσω του γραμμικού αυτού μετασχηματισμού πέφτουμε στις 190 ή 217 ανάλογα τι ποιότητα ανακατασκευής θέλουμε να διατηρήσουμε.

```
Original number of features: 224
Number of PCA components to retain 95% variance: 190
```

```
Original number of features: 224
Number of PCA components to retain 99% variance: 217
```

Choosing Technique

Αφού είδαμε πως δεν υπάρχει κάποια ιδιαίτερη συσχέτιση μεταξύ των features δεν θα καταφύγουμε σε κάποια τεχνική όπως τα Convolutional Neural Networks. Επίσης ο k-NN classifier θα ήταν μια καλή επιλογή ωστόσο το μέγεθος των δεδομένων τον καθιστά απαγορευτικό για λόγους υπολογιστικής ισχύς.

Η επιλογή μας θα είναι αυτή ενός Multilayer Perceptron (MLP).

Hyperparameters

Εφαρμόζουμε StandardScaler στα δεδομένα ώστε να φέρουμε ολα τα χαρακτηριστικά στην ίδια κλίμακα και ύστερα εφαρμόζουμε PCA (ώστε να κυριαρχήσουν οι principal components και όχι τα χαρακτηριστικά με μεγαλύτερη κλίμακα) και διατηρούμε το 95% της variance.

΄Υστερα δοκιμάζουμε διάφορες παραμέτρους για το MLP μας και εφαρμόζουμε 5-fold validation.

Hyperparameters

Το καλύτερο μοντέλο προέκυψε έχοντας 3 κρυφά layers με αριθμό νευρώνων 256,128 και 64 σε κάθε layer. Ως activation function χρησιμοποιήθηκε η ReLU και η έξοδος έχει μέγεθος κόμβων 5 (όσες και οι κλάσεις) με softmax function.

Τα dropout rates είναι 0.4 και 0.3 για αποφυγή overfitting και εφαρμόζουμε Batch Normalization με μέγεθος Batch 64.

Ως optimizer χρησιμοποιείται ο Adam και το learning rate είναι set στην default του τιμή 0.001.

Ως loss function χρησιμοποιείται η Categorical Cross Entropy και ο αριθμός των εποχών είναι 200.

5-fold validation and retraining

Το παραπάνω μοντέλο επιτυγχάνει ακρίβεια περίπου 83% με τις προηγούμενες παραμέτρους και 5-fold validation.

Ύστερα αφού μας ικανοποιούν τα αποτελέσμα αυτά ως ένα ‘simulation’ γενίκευσης επανεκπαιδεύουμε το μοντέλο σε ολόκληρο το training set και φτάνουμε ακρίβεια έως και 98%.

Τέλος μένει να εφαρμόσουμε το μοντέλο αυτό στο datasetTest και να πάρουμε το διάνυσμα labelsX το οποίο αντιστοιχεί στις κλάσεις που προβλέπει το νευρωνικό μας δίκτυο για κάθε test δείγμα.

```
Accuracy: 0.8484848737716675
Fold 2
Accuracy: 0.8330474495887756
Fold 3
Accuracy: 0.8461978435516357
Fold 4
Accuracy: 0.8232265710830688
Fold 5
Accuracy: 0.8340961337089539
5-fold CV accuracy: 0.8370105743408203 ± 0.009276470565763502
```

```
accuracy: 0.9848 - loss: 0.0417
```

Ευχαριστώ πολύ για την προσοχή σας!